stochacalculus

David Peña Peralta

2025-01-11

Table of contents

1 Ecuaciones Diferenciales Estocásticas

Ahora, vamos

2 Tarea 1

Ejecute y explica en pocas palabras la salida del código ex_001.py

```
from scipy.stats import multivariate_normal
from mpl_toolkits.mplot3d import axes3d
from scipy.stats import norm
import numpy as np
from scipy.stats import bernoulli
import matplotlib.pyplot as plt
fig_01, ax_01 = plt.subplots(1, 1)
fig_02, ax_02 = plt.subplots(1, 1)
p = 0.3
mean, var, skew, kurt = bernoulli.stats(p, moments='mvsk')
print(mean, var, skew,kurt)

x = np.arange(bernoulli.ppf(0.01, p), bernoulli.ppf(0.99, p))
ax_01.plot(x, bernoulli.pmf(x, p), 'bo', ms=8, label='bernoulli pmf')
ax_01.vlines(x, 0, bernoulli.pmf(x, p), colors='b', lw=5, alpha=0.5)
r = bernoulli.rvs(p, size=1000)
ax_02.hist(r, bins=200)
plt.show()
```

```
0.3 0.21 0.8728715609439694 -1.2380952380952381
```

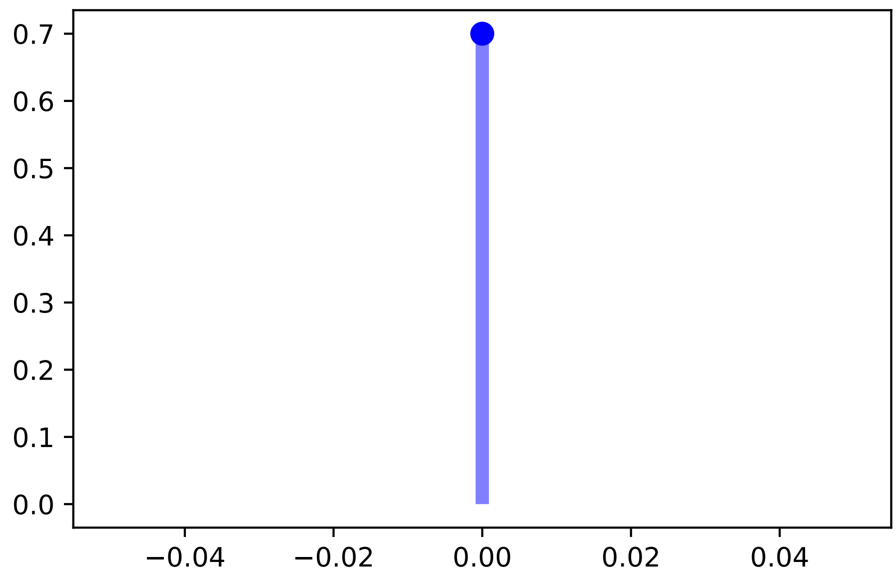

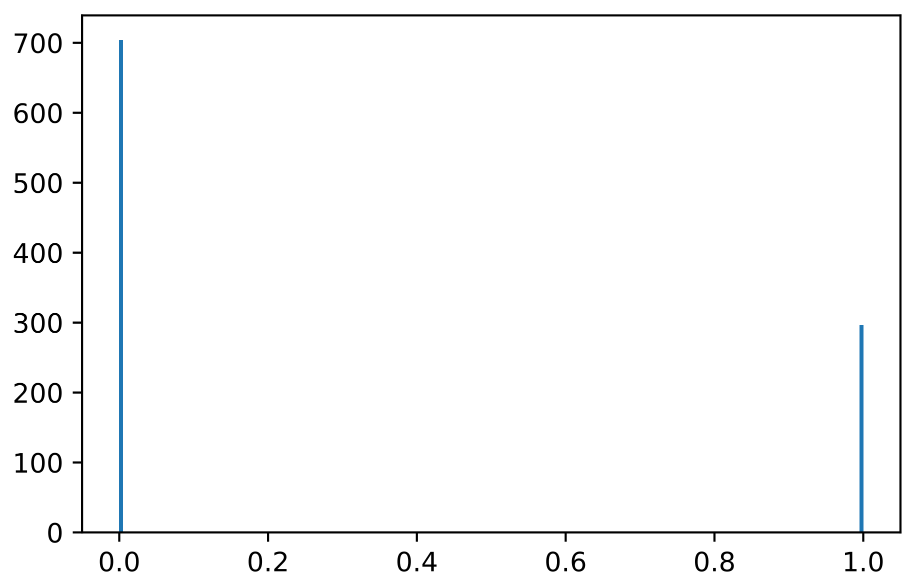

El código posee 3 salidas: * Un vector $[0.3, 0.21, 0.87, -1.23]$ * Dos gráficas.

El vector hace referencia a los momentos de la distribución bernoulli con parámetro $p = 0.3$. * mean hace referencia a la media. * var hace referencia a la varianza. * skew hace referencia al sesgo. * kurt hace referencia a la kurtosis.

Finalmente, las dos gráficas: * La primera hace referencia a la función de probabilidad. Notemos que $\mathcal{P}[X = 0] = 0.7$, lo que muestra la gráfica. Notemos que la gráfica va de -0.04 a 0.04, por lo tanto no se iba a mostrar el caso $X = 1$.
* La segunda hace referencia a una simulación: Se generaron una muestra de tamaño N variables aleatorias con distribución bernoulli. Como la distribución bernoulli tiene media Np, pretende mostrar que en efecto, habrá de forma aproximada Np valores igual a 1 y $N(1-p)$ valores igual a 0.

Ejecute y explica en pocas palabras la salida del código ex_002.py

```
fig, ax = plt.subplots(1, 1)
mean, var, skew, kurt = norm.stats(moments='mvsk')

x = np.linspace(norm.ppf(0.01), norm.ppf(0.99), 100)
ax.plot(
    x,
    norm.pdf(x),
    'r-',
    lw=5,
    alpha=0.6,
    label='norm pdf'
)
rv = norm()
ax.plot(x, rv.pdf(x), 'k-', lw=2, label='frozen pdf')
vals = norm.ppf([0.001, 0.5, 0.999])

np.allclose([0.001, 0.5, 0.999], norm.cdf(vals))

r = norm.rvs(size=50000)

ax.hist(r, density=True, bins='auto', histtype='stepfilled', alpha=0.2)
ax.set_xlim([x[0], x[-1]])
ax.legend(loc='best', frameon=False)
plt.show()
```

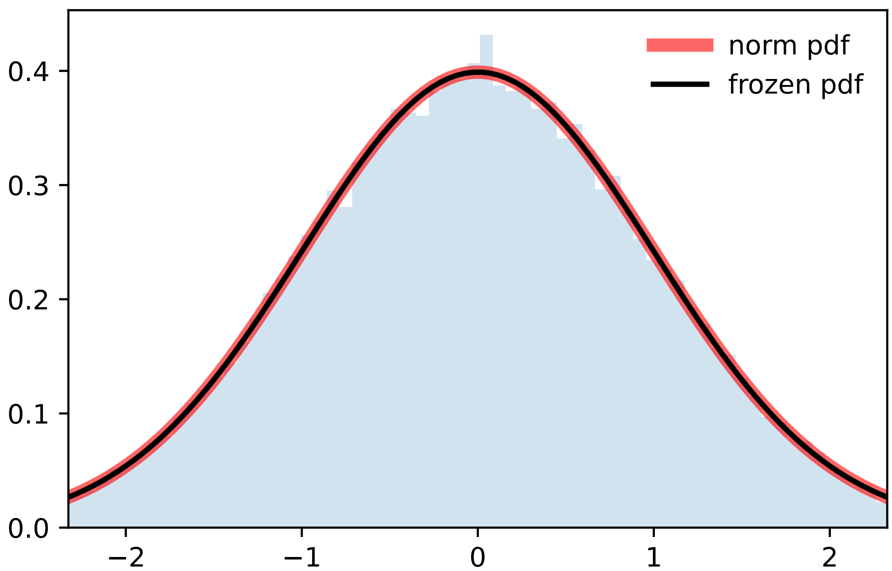

El código posee una gráfica. Que hace referencia a una simulación de variables aleatorias normales. Notemos que * El elemento en azul, hace referencia a un histograma que refleja las frecuencias de los valores generados. * Mientras que la linea roja, muestra la función de densidad de una variable aleatoria estándar.

Ejecute y explica en pocas palabras la salida del código ex_003.py

Para cambiar el vector de medias μ y la matriz Σ hay que prestar atención en la linea donde aparece la función `multivariate_normal()` que de forma simple posee dos parámetros: * El vector de medias $\mu = [0.5, -0.2]$ * La matriz de covarianza $\Sigma = [[2.0, 0.3], [0.3, 0.5]]$

```
x = np.linspace(0, 5, 100, endpoint=False)
y = multivariate_normal.pdf(x, mean=2.5, cov=0.5)

fig1 = plt.figure()
ax = fig1.add_subplot(111)
ax.plot(x, y)
# plt.show()

x, y = np.mgrid[-5:5:.1, -5:5:.1]
pos = np.dstack((x, y))
rv = multivariate_normal([0.1, 0.5], [[3.0, 0.3], [0.75, 1.5]])
fig2 = plt.figure()
ax2 = fig2.add_subplot(111)
ax2.contourf(x, y, rv.pdf(pos))
```

```python
# plt.show()

ax = plt.figure().add_subplot(projection='3d')
ax.plot_surface(
    x,
    y,
    rv.pdf(pos),
    edgecolor='royalblue',
    lw=0.5,
    rstride=8,
    cstride=8,
    alpha=0.4
)
ax.contour(x, y, rv.pdf(pos), zdir='z', offset=-.2, cmap='coolwarm')
ax.contour(x, y, rv.pdf(pos), zdir='x', offset=-5, cmap='coolwarm')
ax.contour(x, y, rv.pdf(pos), zdir='y', offset=5, cmap='coolwarm')

ax.set(
    xlim=(-5, 5),
    ylim=(-5, 5),
    zlim=(-0.2, 0.2),
    xlabel='X',
    ylabel='Y',
    zlabel='Z'
)
plt.show()
```

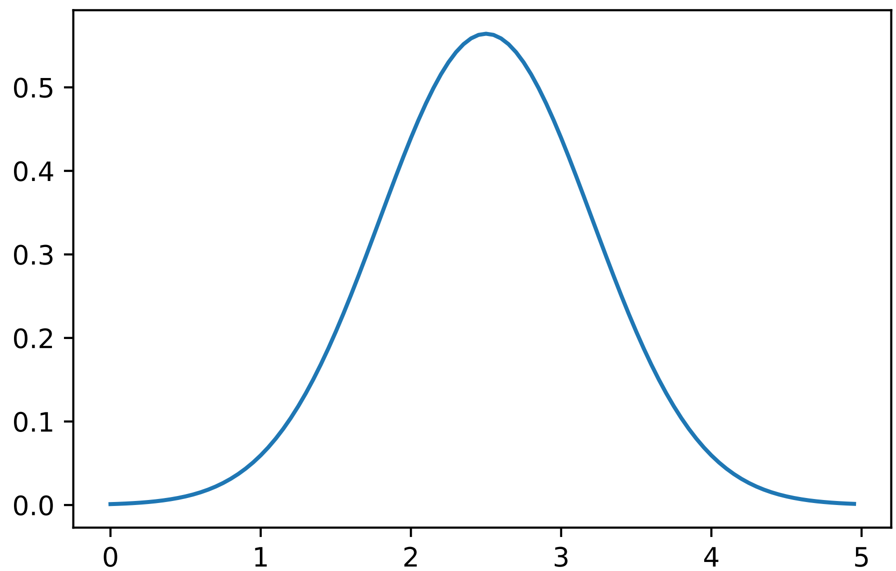
0.5
0.4
0.3
0.2
0.1
0.0
0
1
2
3
4
5

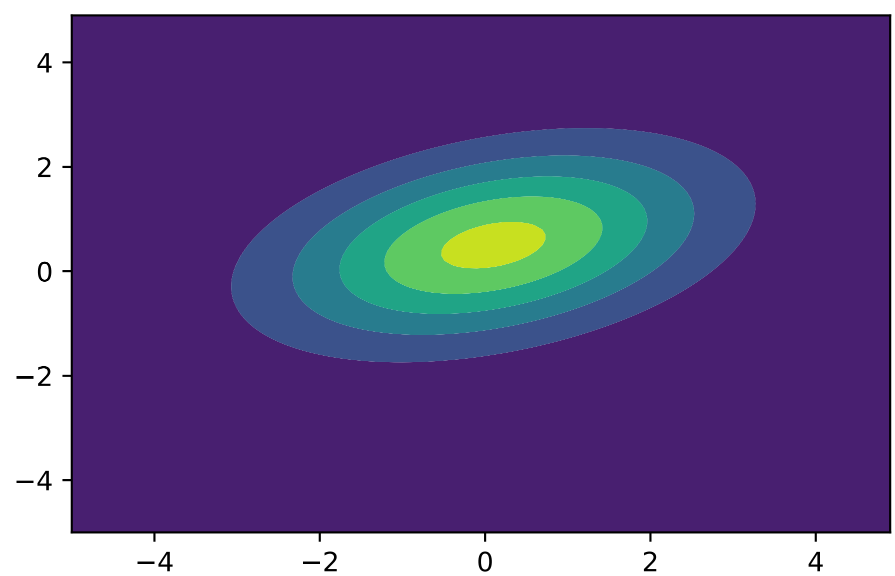
4
2
0
−2
−4
−4
−2
0
2
4

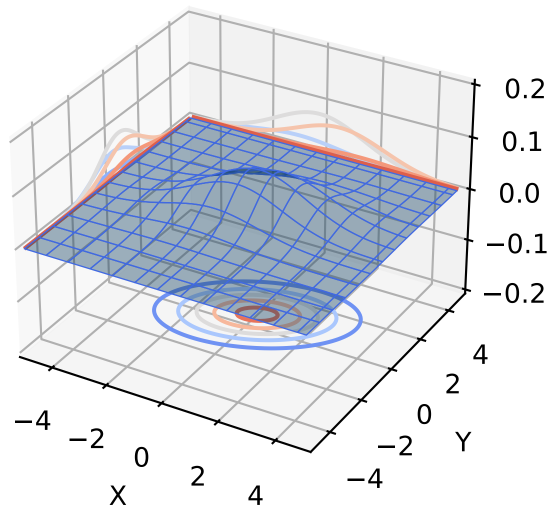

Generando Normales

```
import numpy as np
from scipy.stats import bernoulli
import matplotlib.pyplot as plt

fig_01, ax_01 = plt.subplots(1, 1)
fig_02, ax_02 = plt.subplots(1, 1)

p = 0.3

x = np.arange(bernoulli.ppf(0.01, p), bernoulli.ppf(0.99, p))
ax_01.plot(x, bernoulli.pmf(x, p), 'bo', ms = 8, label = 'bernoulli pmf')
ax_01.vlines(x, 0, bernoulli.pmf(x, p), colors = 'b', lw = 5, alpha = 0.5)

r = bernoulli.rvs(p, size = 1000)
ax_02.hist(r, bins = 200)
```

```
(array([694.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
          0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
          0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
          0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
          0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
          0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
```

```
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,   0.,
        0., 306.]),
array([0.   , 0.005, 0.01 , 0.015, 0.02 , 0.025, 0.03 , 0.035, 0.04 ,
       0.045, 0.05 , 0.055, 0.06 , 0.065, 0.07 , 0.075, 0.08 , 0.085,
       0.09 , 0.095, 0.1  , 0.105, 0.11 , 0.115, 0.12 , 0.125, 0.13 ,
       0.135, 0.14 , 0.145, 0.15 , 0.155, 0.16 , 0.165, 0.17 , 0.175,
       0.18 , 0.185, 0.19 , 0.195, 0.2  , 0.205, 0.21 , 0.215, 0.22 ,
       0.225, 0.23 , 0.235, 0.24 , 0.245, 0.25 , 0.255, 0.26 , 0.265,
       0.27 , 0.275, 0.28 , 0.285, 0.29 , 0.295, 0.3  , 0.305, 0.31 ,
       0.315, 0.32 , 0.325, 0.33 , 0.335, 0.34 , 0.345, 0.35 , 0.355,
       0.36 , 0.365, 0.37 , 0.375, 0.38 , 0.385, 0.39 , 0.395, 0.4  ,
       0.405, 0.41 , 0.415, 0.42 , 0.425, 0.43 , 0.435, 0.44 , 0.445,
       0.45 , 0.455, 0.46 , 0.465, 0.47 , 0.475, 0.48 , 0.485, 0.49 ,
       0.495, 0.5  , 0.505, 0.51 , 0.515, 0.52 , 0.525, 0.53 , 0.535,
       0.54 , 0.545, 0.55 , 0.555, 0.56 , 0.565, 0.57 , 0.575, 0.58 ,
       0.585, 0.59 , 0.595, 0.6  , 0.605, 0.61 , 0.615, 0.62 , 0.625,
       0.63 , 0.635, 0.64 , 0.645, 0.65 , 0.655, 0.66 , 0.665, 0.67 ,
       0.675, 0.68 , 0.685, 0.69 , 0.695, 0.7  , 0.705, 0.71 , 0.715,
       0.72 , 0.725, 0.73 , 0.735, 0.74 , 0.745, 0.75 , 0.755, 0.76 ,
       0.765, 0.77 , 0.775, 0.78 , 0.785, 0.79 , 0.795, 0.8  , 0.805,
       0.81 , 0.815, 0.82 , 0.825, 0.83 , 0.835, 0.84 , 0.845, 0.85 ,
       0.855, 0.86 , 0.865, 0.87 , 0.875, 0.88 , 0.885, 0.89 , 0.895,
       0.9  , 0.905, 0.91 , 0.915, 0.92 , 0.925, 0.93 , 0.935, 0.94 ,
       0.945, 0.95 , 0.955, 0.96 , 0.965, 0.97 , 0.975, 0.98 , 0.985,
       0.99 , 0.995, 1.   ]),
<BarContainer object of 200 artists>)
```

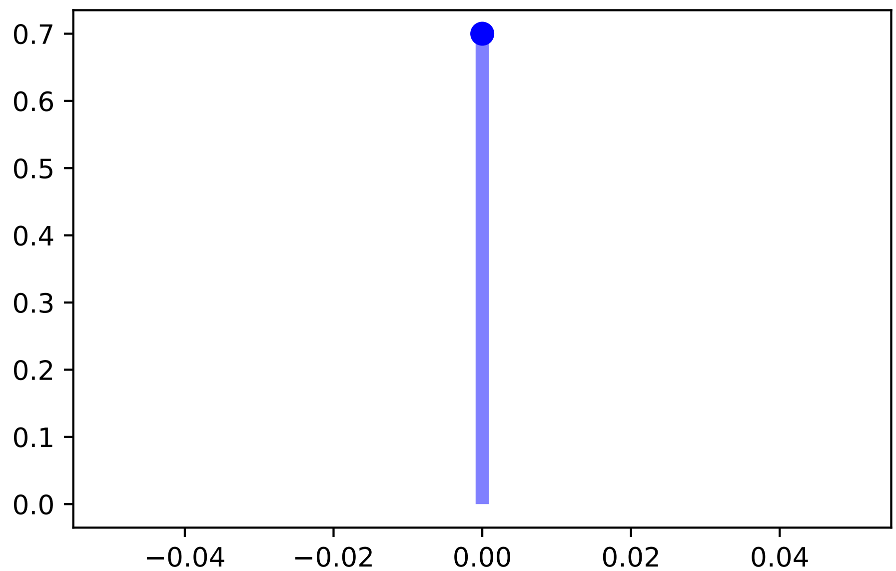

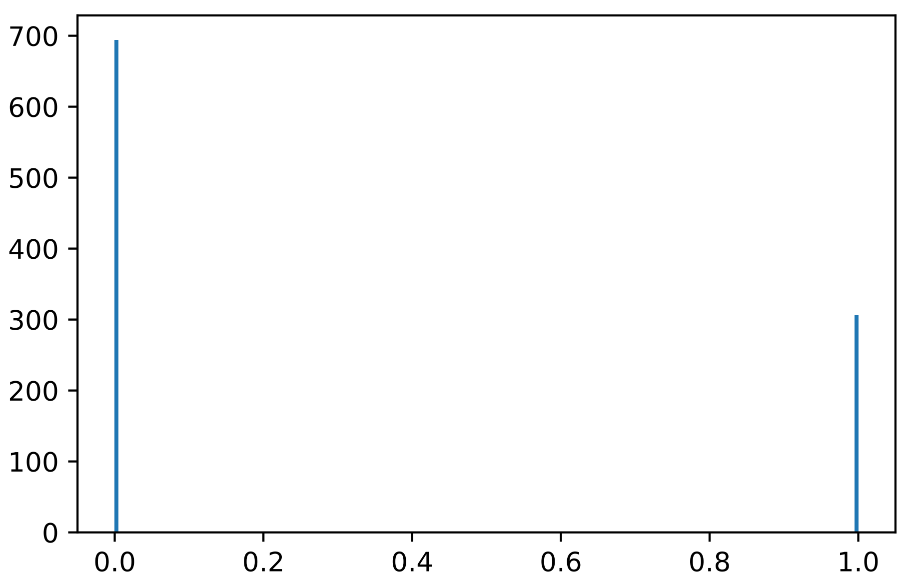


```
from scipy.stats import norm

fig, ax = plt.subplots(1,1)

x = np.linspace(norm.ppf(0.01),norm.ppf(0.99), 100)
```

```python
ax.plot(x, norm.pdf(x),'r-', lw = 5, alpha = 0.6)

r = norm.rvs(size = 1000)

ax.hist(r, density = True, bins = 'auto', histtype = 'stepfilled', alpha = 0.2)
ax.set_xlim(x[0], x[-1])
ax.legend(loc='best', frameon = False)
```

```
No artists with labels found to put in legend.  Note that artists whose label start with an u
```

```
<matplotlib.legend.Legend at 0x202b9c4dbd0>
```

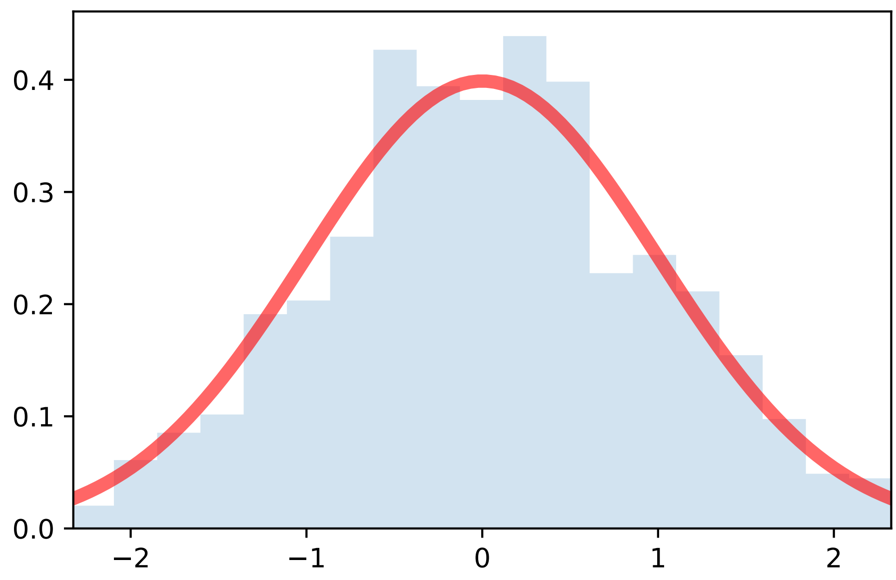


```python
from mpl_toolkits.mplot3d import axes3d
from scipy.stats import multivariate_normal

x = np.linspace(0,5,100,endpoint = False)
y = multivariate_normal.pdf(x , mean = 2.5, cov = 0.5)

fig1 = plt.figure()
ax = fig1.add_subplot(111)
ax.plot(x,y)
```

```
x, y = np.mgrid[-5:5:.1, -5:5:.1]

pos = np.dstack((x,y))
rv = multivariate_normal([0.5, -0.2], [[2.0,0.3], [0.3,0.5]])
fig2 = plt.figure()
ax2 = fig2.add_subplot(111)
ax2.contourf(x,y, rv.pdf(pos))

ax = plt.figure().add_subplot(projection = '3d')
ax.plot_surface(x,
                y,
                rv.pdf(pos),
                edgecolor = 'royalblue',
                lw = 0.5,
                rstride = 8,
                cstride = 8,
                alpha = 0.5)
```

```
<mpl_toolkits.mplot3d.art3d.Poly3DCollection at 0x202b9d06b10>
```

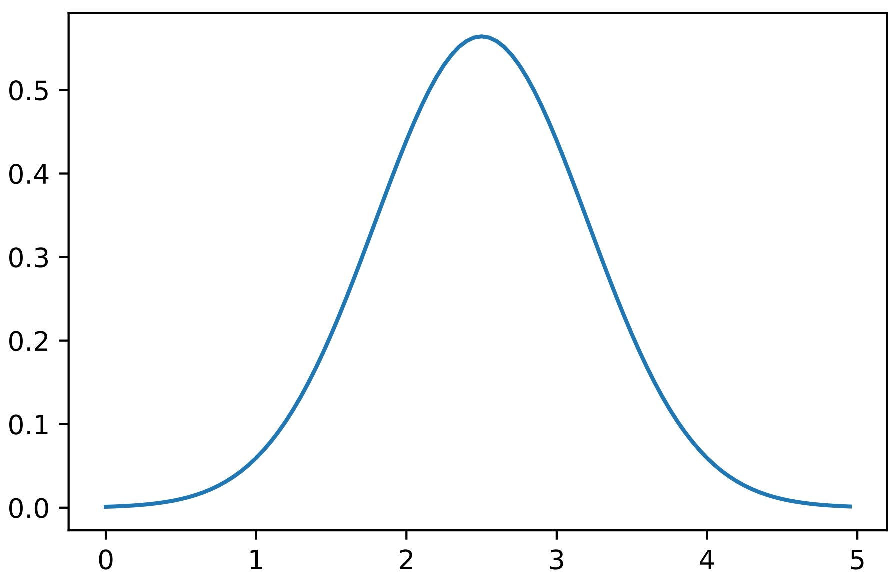

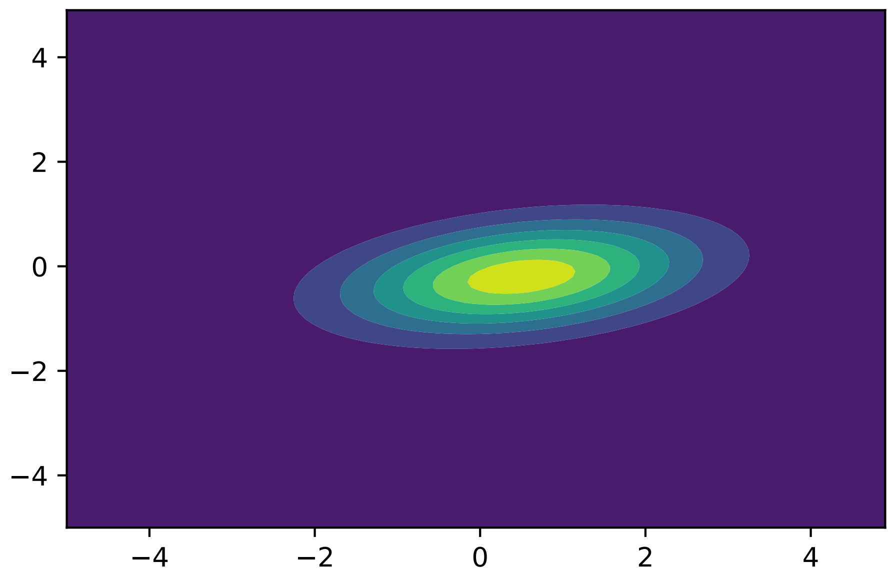

4
2
0
−2
−4
−4
−2
0
2
4

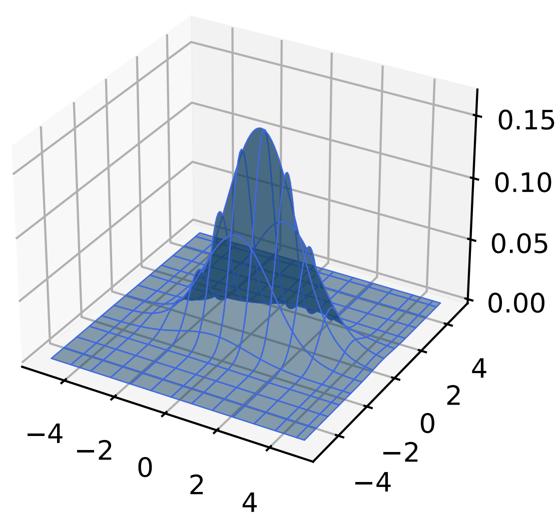

0.15
0.10
0.05
0.00
−4
−2
0
2
4
4
2
0
−2
−4

3 Tarea 2

Sea X_i v.a.i.i.d tales que

$$\mathcal{P}\left[X_i = h\right] = \mathcal{P}\left[X_i = -h\right] = \frac{1}{2}, \forall i,$$

entonces definimos $Y_{n,h}$. ::: Queremos calcular la función característica de $Y_{n,\delta}$.

$$E\left[i\lambda Y_{n,\delta}\left(t\right)\right],$$

Aprovechando que para cada X_i son v.a.i.i.d. Entonces, tenemos lo siguiente

$$\begin{aligned} E\left[i\lambda Y_{n,\delta}\left(t\right)\right] &= \left(\cos\left(\lambda h\right)\right)^{t/\delta} \\ &= u^t, \end{aligned}$$

donde

$$\begin{aligned} u &= \left[\cos\left(\lambda h\right)\right]^{1/\delta} \\ \ln\left(u\right) &= \frac{1}{\delta}\ln\left[\cos\left(\lambda h\right)\right] \end{aligned}$$

Entonces, aproximaremos $\cos\left(\lambda h\right)$ con su expansión de Taylor.

$$\cos\left(\lambda h\right) \approx 1 - \frac{\left(\lambda h\right)^2}{2!} + \frac{\left(\lambda h\right)^4}{4!},$$

entonces

$$\begin{aligned} \ln\left(\cos\left(\lambda h\right)\right) &\approx \ln\left[1 - \frac{\left(\lambda h\right)^2}{2} + \frac{\left(\lambda h\right)^4}{4!}\right] \\ &\approx -\frac{\left(\lambda h\right)^2}{2!} + \frac{\left(\lambda h\right)^4}{4!} \end{aligned}$$

Entonces

$$
\begin{aligned}
u^t &\approx \exp\left[\frac{t}{\delta}\left(-\frac{(\lambda h)^2}{2!}+\frac{(\lambda h)^4}{4!}\right)\right],\\
&\approx \exp\left[-\frac{t}{\delta}\left(\frac{\lambda^2 h^2}{2}-\frac{\lambda^4 h^4}{24}\right)\right],
\end{aligned}
$$

Calculando el limite

$$
\lim_{\delta\to 0} E\left[\exp\left(i\lambda Y_{n,\delta}(t)\right)\right]=\lim_{\delta\to 0}\exp\left[-t\left(\left[\frac{h^2}{\delta}\right]\left(\frac{\lambda^2}{2}-\frac{\lambda^4 h^2}{24}\right)\right)\right],
$$

si $h^2/\delta \to \infty$ Segun la sucesión $\delta_n \to 0$ tenemos limites diferentes, por lo tanto, este no existe. Ahora, usando la normalización, retomando las operaciones anteriores,

$$
\begin{aligned}
E\left[\exp\left(i\lambda Y_{n,\delta}(t)+\frac{th^2\lambda^2}{2}\right)\right] &= E\left[\exp\left(i\lambda\sum_{i=0}^{n} X_i+\frac{th^2\lambda^2}{2\delta}\right)\right]\\
&= E\left[\exp\left(i\lambda\sum_{i=0}^{n} X_i\right)\right]\exp\left(\frac{th^2\lambda^2}{2\delta}\right)\\
&= \left(\left[\cos(\lambda h)\right]^{1/\delta}\exp\left(\frac{h^2\lambda^2}{2\delta}\right)\right)^t,
\end{aligned}
$$

entonces,

$$
\begin{aligned}
v &= \left[\cos(\lambda h)\right]^{1/\delta}\exp\left(\frac{h^2\lambda^2}{2}\right)\\
\ln v &= \ln\left[\left[\cos(\lambda h)\right]^{1/\delta}\exp\left(\frac{h^2\lambda^2}{2}\right)\right]\\
&= \frac{1}{\delta}\ln\left[\cos(\lambda h)\right]+\frac{h^2\lambda^2}{2\delta}\\
&= \frac{1}{\delta}\left(\ln\left[\cos(\lambda h)\right]+\frac{h^2\lambda^2}{2}\right)\\
&\approx \frac{1}{\delta}\left(\ln\left[1\underbrace{-\frac{(\lambda h)^2}{2}+\frac{(\lambda h)^4}{4!}}_{x_0}\right]+\frac{h^2\lambda^2}{2}\right)
\end{aligned}
$$

recordando que

$$
\ln(1+x)\approx x-\frac{x^2}{2},
$$

entonces

$$\ln v \approx \frac{1}{\delta}\left(\left[-\frac{(\lambda h)^2}{2}+\frac{(\lambda h)^4}{4!}-\frac{\left(-\frac{(\lambda h)^2}{2}+\frac{(\lambda h)^4}{4!}\right)^2}{2}\right]+\frac{h^2\lambda^2}{2}\right),$$

bajo la simplificación de que $o\left(h^k\right)\equiv 0, k\geq 4$, entonces

$$\begin{aligned}\ln v &\approx \frac{1}{\delta}\left(\frac{(\lambda h)^4}{24}-\frac{(\lambda h)^4}{8}\right)\\ &\approx \frac{1}{\delta}\left(\frac{(\lambda h)^4}{24}-\frac{3\,(\lambda h)^4}{24}\right)\\ v &\approx \exp\left(-\frac{(\lambda h)^4}{12\delta}\right)\end{aligned}$$

por lo tanto, si $h^4/\delta \to 0$

$$\lim_{\delta\to 0} E\left[\exp\left(i\lambda Y_{n,\delta}\left(t\right)+\frac{th^2\lambda^2}{2}\right)\right]=\lim_{\delta\to 0}\exp\left(-\frac{(\lambda h)^4}{12\delta}\right)=1$$

4 Tarea 3

5 Ejercicio 3.1

Si $X \sim N(\mu, \sigma)$ entonces $\left(\dfrac{X-\mu}{\sigma}\right) \sim N(0,1)$.

Calculemos la función característica de la variable $\dfrac{X-\mu}{\sigma}$,

$$
\begin{aligned}
\varphi_{\frac{X-\mu}{\sigma}}(t) &= E\left[e^{it\left(\frac{X-\mu}{\sigma}\right)}\right] \\
&= E\left[e^{\left(\frac{itX}{\sigma}-\frac{it\mu}{\sigma}\right)}\right] \\
&= e^{-\frac{it\mu}{\sigma}} E\left[e^{\left(\frac{itX}{\sigma}\right)}\right] \\
&= e^{-\frac{it\mu}{\sigma}} \int_{-\infty}^{\infty} e^{\frac{itx}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}\, dx \\
&= e^{-\frac{it\mu}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{\frac{itx}{\sigma}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}\, dx \\
&= e^{-\frac{it\mu}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{\frac{itx}{\sigma}-\frac{(x-\mu)^2}{2\sigma^2}}\, dx \\
&= e^{-\frac{it\mu}{\sigma}} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}\frac{(x-\mu)^2-2itx\sigma}{\sigma^2}}\, dx
\end{aligned} \tag{5.1}
$$

Observemos que,

$$
\begin{aligned}
\frac{(x-\mu)^2-2itx\sigma}{\sigma^2} &= \frac{x^2-2x\mu+\mu^2-2itx\sigma}{\sigma^2} \\
&= \frac{x^2}{\sigma^2} - \frac{2x\mu}{\sigma^2} + \frac{\mu^2}{\sigma^2} - \frac{2itx\sigma}{\sigma^2} \\
&= \frac{x^2}{\sigma^2} - \frac{2x}{\sigma}\left(\frac{\mu+it\sigma}{\sigma^2}\right) + \frac{\mu^2}{\sigma^2} \\
&= \left(\frac{x}{\sigma} - \left(\frac{\mu+it\sigma}{\sigma}\right)\right)^2 - \left(\frac{\mu+it\sigma}{\sigma}\right)^2 + \frac{\mu^2}{\sigma^2} \\
&= \left(\frac{x}{\sigma} - \left(\frac{\mu+it\sigma}{\sigma}\right)\right)^2 - \frac{2it\sigma\mu}{\sigma^2} - \frac{(it\sigma)^2}{\sigma^2} \\
&= \left(\frac{x}{\sigma} - \left(\frac{\mu+it\sigma}{\sigma}\right)\right)^2 - \frac{2it\mu}{\sigma} + t^2.
\end{aligned} \tag{5.2}
$$

Sustituyendo (5.2) en (5.1), resulta

$$\begin{aligned}
\varphi_{\frac{X-\mu}{\sigma}}(t) &= e^{-\frac{it\mu}{\sigma}}\frac{1}{\sigma\sqrt{2\pi}}\int_{-\infty}^{\infty}e^{-\frac{1}{2}\left[\left(\frac{x}{\sigma}-\left(\frac{\mu+it\sigma}{\sigma}\right)\right)^2-\frac{2it\mu}{\sigma}+t^2\right]}dx \\
&= e^{-\frac{it\mu}{\sigma}}e^{\frac{it\mu}{\sigma}-\frac{t^2}{2}}\frac{1}{\sigma\sqrt{2\pi}}\int_{-\infty}^{\infty}e^{-\frac{1}{2}\left(\frac{x}{\sigma}-\left(\frac{\mu+it\sigma}{\sigma}\right)\right)^2}dx \\
&= e^{-\frac{t^2}{2}}\frac{1}{\sigma\sqrt{2\pi}}\int_{-\infty}^{\infty}e^{-\frac{1}{2}\left(\frac{x}{\sigma}-\left(\frac{\mu+it\sigma}{\sigma}\right)\right)^2}dx \qquad (5.3)
\end{aligned}$$

Sea $u=\frac{x}{\sigma}-\left(\frac{\mu+it\sigma}{\sigma}\right)\Longrightarrow du=\frac{1}{\sigma}dx$, sustituyendo esto en (5.3), resulta

$$\varphi_{\frac{X-\mu}{\sigma}}(t)=e^{-\frac{t^2}{2}}\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty}e^{-\frac{u^2}{2}}du \qquad (5.4)$$

de aquí se sigue que $u\sim N(0,1)$, entonces

$$\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty}e^{-\frac{u^2}{2}}dx=1.$$

sustituyendo esto ultimo en (5.4), se tiene,

$$\varphi_{\frac{X-\mu}{\sigma}}(t)=e^{-\frac{t^2}{2}},$$

que es la función característica de una Normal estándar, como las funciones características coinciden se concluye que $\frac{X-\mu}{\sigma}\sim N(0,1)$.

6 Ejercicio 3.2

Si $Y \sim N(0,1)$ entonces $\sigma Y + \mu \sim N(\mu, \sigma)$. Calculemos la función característica de la variable $\sigma Y + \mu$,

$$
\begin{aligned}
\varphi_{\sigma Y+\mu}(t) &= E\left[e^{it(\sigma Y+\mu)}\right] \\
&= E\left[e^{it\sigma Y+it\mu}\right] \\
&= e^{it\mu}E\left[e^{it\sigma Y}\right] \\
&= e^{it\mu}\int_{-\infty}^{\infty} e^{it\sigma y}\frac{1}{\sqrt{2\pi}}e^{\frac{-y^2}{2}}dy \\
&= e^{it\mu}\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-\frac{1}{2}(y^2-2yit\sigma)}dy. \qquad (6.1)
\end{aligned}
$$

Observemos que,

$$
\begin{aligned}
y^2 - 2yit\sigma &= (y-it\sigma)^2 - (it\sigma)^2 \\
&= (y-it\sigma)^2 + t^2\sigma^2. \qquad (6.2)
\end{aligned}
$$

Sustituyendo, (6.2) en (6.1) resulta

$$
\begin{aligned}
\varphi_{\sigma Y+\mu}(t) &= e^{it\mu}\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-\frac{1}{2}((y-it\sigma)^2+t^2\sigma^2)}dy \\
&= e^{it\mu}e^{-\frac{1}{2}t^2\sigma^2}\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-\frac{1}{2}(y-it\sigma)^2}dy \qquad (6.3)
\end{aligned}
$$

Tomando $u = y - it\sigma \Longrightarrow du = dy$, se tiene que

$$
\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-\frac{1}{2}(y-it\sigma)^2}dy = \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-\frac{u^2}{2}}du,
$$

entonces $U \sim N(0,1)$, por lo tanto,

$$
\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} e^{-\frac{1}{2}(y-it\sigma)^2}dy = 1
$$

sustituyendo esto ultimo en (6.3), resulta,

$$\varphi_{\sigma Y+\mu}(t) = e^{it\mu}e^{-\frac{1}{2}t^2\sigma^2} = e^{it\mu - \frac{t^2\sigma^2}{2}}.$$

Sea Z una variable aleatoria tal que $Z \sim N(\mu, \sigma)$ sabemos que,

$$\varphi_Z(t) = e^{it\mu - \frac{t^2\sigma^2}{2}}.$$

De estas dos ultimas igualdades se sigue que,

$$\varphi_Z(t) = \varphi_{\sigma Y+\mu}(t).$$

Dado que tienen iguales funciones características se concluye que,

$$\sigma Y + \mu \sim N(\mu, \sigma)$$

7 Ejercicio 3.3

Si $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$ además X y Y son independientes entonces $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$. Por definición, se tiene que,

$$\begin{aligned}
\varphi_{X+Y}(t) &= E[e^{it(X+Y)}] \\
&= E[e^{itX}e^{itY}] \text{ por ser independientes, del ejercicio 4} \\
&= E[e^{itX}]E[e^{itY}] \\
&= \varphi_X(t)\varphi_Y(t). \qquad (7.1)
\end{aligned}$$

Por otro lado, sea Z una variables aleatoria tal que, $Z \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$, sabemos que la función característica de Z, esta dada por,

$$\begin{aligned}
\varphi_Z(t) = &\quad e^{it(\mu_1+\mu_2)-\frac{t^2}{2}(\sigma_1^2+\sigma_2^2)} \\
= &\quad e^{it\mu_1-\frac{t^2\sigma_1^2}{2}+it\mu_2-\frac{t^2\sigma_2^2}{2}} \\
= &\quad e^{it\mu_1-\frac{t^2\sigma_1^2}{2}}e^{it\mu_2-\frac{t^2\sigma_2^2}{2}} \\
= &\quad \varphi_X(t)\varphi_Y(t),
\end{aligned}$$

entonces, de esta ultima igualdad y de (**??**) se sigue que,

$$\varphi_Z(t) = \varphi_{X+Y}(t).$$

Como las funciones características coinciden se sigue que, $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

8 Ejercicio 3.4

Si X, Y son variables normales independientes. Entonces $E[XY] = E[X]E[Y]$.

Recrodemos que

$$E[XY] = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} xyf_{XY}(x,y)\,\mathrm{d}x\mathrm{d}y$$

Como X, Y son independientes

$$f_{XY}(x,y) = f_X(x)\,f_Y(y)$$

Entonces

$$\begin{aligned}
E[XY] &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} xyf_{XY}(x,y)\,\mathrm{d}x\mathrm{d}y \\
&= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} xyf_X(x)\,f_y(y)\,\mathrm{d}x\mathrm{d}y \\
&= \left[\int_{-\infty}^{\infty} xf_X(x)\,\mathrm{d}x\right]\left[\int_{-\infty}^{\infty} yf_y(y)\,\mathrm{d}y\right] \\
&= E[X]\,E[Y]
\end{aligned}$$

9 Ejercicio 3.5

Por Demostrar

$$\mathcal{P}\left[|X-\mu| \geq \epsilon\right] \leq \frac{\mathrm{Var}\left[X\right]}{\epsilon^2}$$

Por la desigualdad de Chebysev, para X una variable aleatoria.

$$\mathcal{P}\left[X \geq \epsilon\right] \leq \frac{E\left[X\right]}{\epsilon}$$

Entonces, sea $Y = |X-\mu|\,, \mu = E\left[X\right]$

$$\begin{aligned}\mathcal{P}\left[|X-\mu| \geq \epsilon\right] &= \mathcal{P}\left[|X-\mu|^2 \geq \epsilon^2\right] \\ &\leq \frac{E\left[(X-\mu)^2\right]}{\epsilon^2} = \frac{\mathrm{Var}\left[X\right]}{\epsilon^2}\end{aligned}$$

10 Ejercicio 3.6 (Ley de los grandes números)

Por demostrar

Sean $X_1, X_2, ..., X_n$ variables aleatorias independienes con esperanza finita $\mu = E\left[X_j\right]$ y varianza infinita. $\sigma^2 = \mathrm{Var}\left(X_j\right)$. Sean $S_n = X_1 + X_2 + ... + X_n$. Entonces para cada $\epsilon > 0$.

$$\mathcal{P}\left[\left|\frac{S_n}{n} - \mu\right| \geq \epsilon\right] \to 0$$

Notemos que

$$\begin{aligned}\mathrm{Var}\left[\frac{S_n}{n} - \mu\right] &= \frac{1}{n^2}\mathrm{Var}\left(S_n\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}\left(X_i\right) \\ &= \frac{\sigma^2}{n}\end{aligned}$$

Entonces, por el Teorema de Chebysev

$$\mathcal{P}\left[\left|\frac{S_n}{n} - \mu\right| \geq \epsilon\right] \leq \frac{\sigma^2}{n\epsilon},$$

notemos que para $n \to \infty$

$$\frac{\sigma^2}{n\epsilon} \to 0.$$

Entonces

$$\mathcal{P}\left[\left|\frac{S_n}{n} - \mu\right| \geq \epsilon\right] \to 0$$

11 Ejercicio 3.7 (Teorema de Limite Central)

Sea $\{X_i\}_{i=1}^{\infty}$ una secuencia de v.a.i.id con media a y varianza b^2. Entonces para doo $\alpha, \beta \in \mathbb{R}$, con $\alpha < \beta$, entonces

$$\mathcal{P}\left(\lim_{M\to\infty} \alpha \leq \frac{\displaystyle\sum_{i=1}^{M} X_i - Ma}{\sqrt{M}b} \leq \beta\right) = \frac{1}{\sqrt{2\pi}} \int_{\alpha}^{\beta} \exp\left(-\frac{1}{2}x^2\right) \mathrm{d}x$$

Sea

$$Y_M = \frac{\displaystyle\sum_{i=1}^{M} [X_i - a]}{\sqrt{M}b},$$

Definamos

$$\overline{S_M} = \sum_{i=1}^{M} [X_i - a],$$

entonces

$$Y_M = \frac{S_M}{\sqrt{M}b}$$

demostraremos que la función generadora de momentos $\varphi_M \to \varphi$ donde $\varphi_m = \varphi_{Y_M}$ y φ es función generadora de momentos de la distribución normal estandar.

Ahora,

$$\begin{aligned}
\varphi_M(t) &= E\left[\exp\left(t\frac{S_M}{\sqrt{M}b}\right)\right] \\
&= \varphi_{SM}\left(\frac{t}{\sqrt{M}b}\right) \\
X_i \text{ v.a.i.i.d} \Rightarrow &= \left[\varphi_{(X_1-a)}\left(\frac{t}{\sqrt{M}b}\right)\right]^M \\
&= \left[E\left[\exp\left(\frac{t}{b\sqrt{M}}(X_1-a)\right)\right]\right]
\end{aligned}$$

Recordando la serie de Taylor

$$\begin{aligned}
\varphi_M(t) &= \left[\sum_{i=0}^{\infty} \frac{E\left[\left(\frac{t}{b\sqrt{M}} (X_1 - a) \right)^i \right]}{i!} \right]^M \\
&= \left[1 + \frac{1}{2} \left(\frac{t}{b\sqrt{M}} \right)^2 E\left[(X_1 - a)^2 \right] + \epsilon(3) \right]^M \\
&= \left[1 + \frac{1}{M} \frac{t^2}{2} + \epsilon(3) \right]^M,
\end{aligned}$$

donde

$$\epsilon(3) = \sum_{i=3}^{\infty} \frac{E\left[\left(\frac{t}{b\sqrt{M}} (X_1 - a) \right)^i \right]}{i!},$$

Sea $s = \frac{t}{b\sqrt{M}}$, entonces $s \to 0, t \to 0$

$$\epsilon(3) = \sum_{i=3}^{\infty} \frac{E\left[(X_1 - a)^i \right] s^i}{i!}$$

Notemos que, si φ_1 existe. Entonces

$$\frac{\epsilon(3)}{s^2} = \sum_{i=3}^{\infty} \frac{E\left[(X_1 - a)^i \right] s^{i-2}}{i!} \to 0, s \to 0.$$

Además $s \to 0$ cuando $M \to \infty$.

$$\Rightarrow \varphi_M(t) = \left[1 + \frac{1}{M} \left[\frac{t^2}{2} + M\epsilon(3) \right] \right]^M,$$

Entonces $\epsilon(3)\, s^{-2} = Me(3)\, b^2 t^{-2} \to 0$. Como b, t estan fijas.

$$M\epsilon(3) \to 0, M \to \infty,$$

por lo tanto

$$\frac{t^2}{2} + M\epsilon\left(3\right) \to \frac{t^2}{2}, M \to \infty$$

$$\left[1 + \frac{1}{M}\left[\frac{t^2}{2} + M\epsilon\left(3\right)\right]\right]^M \to \exp\left(t^2\right), M \to \infty$$

$$\lim_{M\to\infty} \varphi_M\left(t\right) = \exp\left(t^2\right) = \varphi\left(t\right),$$

la función generadora de momentos de la distribución normal estándar. Por lo tanto

$$F_M\left(x\right) \to F_{N(0,1)}\left(x\right)$$

$$F_M\left(b\right) - F_M\left(a\right) \to F_N\left(b\right) - F_N\left(a\right)$$

$$\mathcal{P}\left(\lim_{M\to\infty} \alpha \leq \frac{\sum_{i=1}^{M} X_i - Ma}{\sqrt{M}b} \leq \beta\right) = \frac{1}{\sqrt{2\pi}} \int_\alpha^\beta \exp\left(-\frac{1}{2}x^2\right) \mathrm{d}x$$

12 Ejercicio 3.8

Sea $\{X_i\}_{i=1}^{\infty}$ una sucesión de v.a.i.i.d con media a. Entonces

$$\mathcal{P}\left[\lim_{M\to\infty}\frac{1}{M}\sum_{i=1}^{M}X_i=a\right]=1.$$

Esto es similar a decir que

$$\lim_{M\to\infty}\frac{1}{M}\sum_{i=1}^{M}X_i\overset{\text{c.s}}{=}a$$

Sin perdida de generalidad, diremos que $X_i\geq 0,\forall i$. Definamos

$$Y_n=X_nI_{[|X_n|\leq n]},Q_n=\sum_{i=1}^{n}Y_i$$

Por la desigualdad de

$$\begin{aligned}\sum_{n=1}^{\infty}\mathcal{P}\left[\left|\frac{Q_n-E\left[Q_n\right]}{n}\right|\geq\epsilon\right]&\leq\sum_{n=1}^{\infty}\frac{\operatorname{Var}\left(Q_n\right)}{\epsilon^2n^2}=\sum_{n=1}^{\infty}\frac{1}{\epsilon^2n^2}\sum_{i=1}^{n}\operatorname{Var}\left(Y_i\right)\\&\leq\sum_{n=1}^{\infty}\frac{E\left(Y_n^2\right)}{\epsilon^2n^2}=\sum_{n=1}^{\infty}\frac{1}{\epsilon^2n^2}\int_0^n x^2\mathrm{d}F\\&\leq\sum_{n=1}^{\infty}\frac{1}{\epsilon^2}\int_0^n x\mathrm{d}F<\infty,\end{aligned}$$

donde F es la función de distribución de X_i. Luego

$$E\left[X_1\right]=\lim_{n\to\infty}\int_0^n x\mathrm{d}F=\lim_{n\to\infty}E\left[Y_n\right]=\lim_{n\to\infty}\frac{E\left[Q_n\right]}{n}.$$

Entonces, por el Lema de Borel Canteli. $\mathcal{P}\left[\limsup\left(\left|\frac{Q_n-E\left[Q_n\right]}{n}\right|\geq\epsilon\right)\right]=0$

$$\lim_{n\to\infty}\frac{Q_n}{n}=E\left[X_1\right],\text{c.s}$$

Ahora, calcularemos la siguiente probabilidad

$$\sum_{i=1}^{\infty} \mathcal{P}\left[X_i \neq Y_i\right] = \sum_{i=1}^{\infty} \mathcal{P}\left[X_i > n\right]$$

como $E\left[X_i\right] < \infty$ y X_i son v.a.i.i.d.

$$\sum_{i=1}^{\infty} \mathcal{P}\left[X_i > n\right] \leq E\left[X_1\right] < \infty$$

De nuevo, por el Lema de Borel Cantelli.

$$\mathcal{P}\left[\limsup\left[X_i \neq Y_i\right]\right] = 0, \forall i$$

Entonces

$$\begin{aligned} & X_i = Y_i, \text{c.s} \\ \Rightarrow & \frac{1}{M} \sum_{i=1}^{M} X_i \rightarrow E\left[X_1\right] = \mu. \text{ c.s} \end{aligned}$$

13 Tarea 4

Sea $W(t)$ un movimiento Browniano estándar en $[0, T]$. Pruebe que para cualquier $c > 0$ fijo,

$$V(t) = \frac{1}{c} W(c^2 t)$$

es un movimiento Browniano sobre $[0, T]$.

13.0.1 Demostración

Demostraremos que V cumple las propiedades del movimiento Browniano.

13.0.1.1 Propiedad 1

Es claro que $V(0) = \dfrac{1}{c} W(c^2 0) = 0$.

13.0.1.2 Propiedad 2 (Incrementos Independientes)

Sean $s < t < u < v$ tenemos que

$$E[(V(t) - V(s))\,(V(v) - V(u))] = \frac{1}{c^2} E[(W(c^2 t) - W(c^2 s))\,(W(c^2 v) - W(c^2 u))]$$

Como el browniano tiene incrementos independientes.

$$\begin{aligned}\frac{1}{c^2} E\left[(W(c^2 t) - W(c^2 s))\,(W(c^2 v) - W(c^2 u))\right] &= \frac{1}{c^2} E\left[(W(c^2 t) - W(c^2 s))\right] E\left[(W(c^2 v) - W(c^2 u))\right] \\ &= 0\end{aligned}$$

Entonces V tiene incrementos independientes.

13.0.1.3 Propiedad 3 (Incrementos estacionarios)

Considere $s < t$.

$$V(t) - V(s) = \frac{1}{c}\left[W(c^2 t) - W(c^2 s)\right]$$

Por propiedades del movimiento Browniano.

$$\begin{aligned} E\left[V(t) - V(s)\right] &= \frac{1}{c} E\left[W(c^2 t) - W(c^2 s)\right] = 0 \\ \operatorname{Var}\left[V(t) - V(s)\right] &= \frac{1}{c^2} \operatorname{Var}\left[W(c^2 t) - W(c^2 s)\right] = \frac{1}{c^2}\left(c^2 (t-s)\right) = t - s \end{aligned}$$

Entonces V tiene incrementos estacionarios.

13.0.2 Por lo tanto, V es un movimiento browniano.

Hacer un script para ilustrar la propiedad de escalado del movimiento Browniano para el caso de $c = \frac{1}{5}$. Estar seguro que usa el mismo camino browniano discretizado en cada subplot.

El código, se encuentra en `hw4_p2.py`. Pero aquí se muestran los resultados.

```
# Importamos las librerias necesarias
import numpy as np
import matplotlib.pyplot as plt

# Comenzaremos simulando el movimiento browniano fuerte.

prng = np.random.RandomState(10)  # Fijamos la semilla.

t_final = 1  # Extremo derecho del intervalo [0,T]
n_points = 64  # No olvidemos que aquí se incluye el 0 y t.
dt = 1 / (n_points - 1)  # Ajuste al delta t

dw = np.sqrt(dt) * prng.standard_normal(n_points - 1)  # Calculamos los incrementos.
w = np.concatenate(([0], dw.cumsum()))

time = np.linspace(0, t_final, n_points)  # Vector de tiempo.

# plt.plot(time, w)        Graficamos el browniano base.
# plt.show()
```

```python
"""
Ahora, comenzamos con el browniano escalado.
"""
c = 0.2  # 1/5


"""
Esto tiene dos interpretaciones.
Sin embargo, para este ejercicio debemos partir de una trayectoria dada, entonces haremos
"""

c_time = c**2 * time  # Transformamos el intervalo del tiempo
c_w = c**(-1) * w  # Escalamos el browniano.

print("El valor de c es ",c)
fig, cbrown = plt.subplots(2)
cbrown[0].plot(time, w)
cbrown[1].plot(c_time, c_w)
cbrown[0].set_title('Movimiento browniano')
cbrown[1].set_title('Movimiento browniano escalado')
plt.show()
```

```
El valor de c es  0.2
```

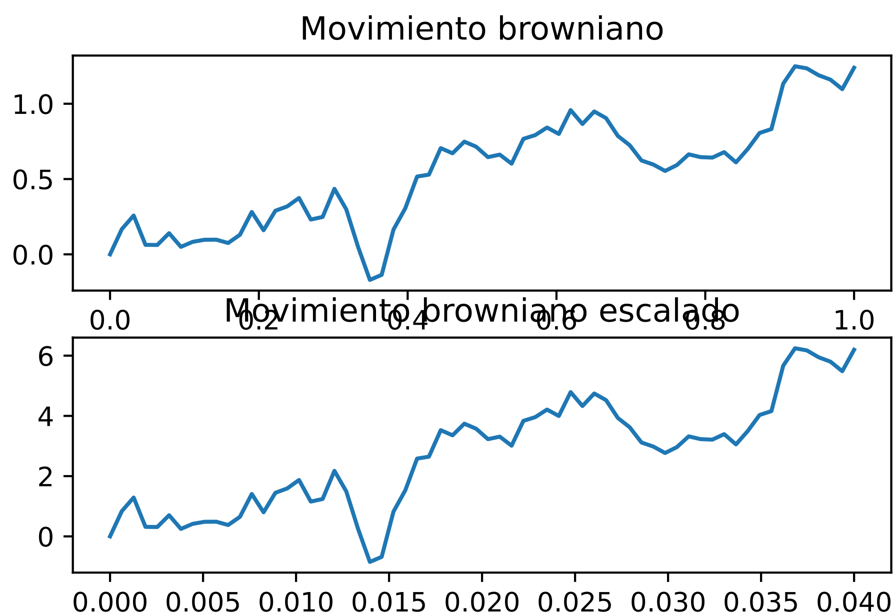

Modifique el script `half_brownian_refinement.py` encapsulando el código en una función. Esta función deberá recibir el extremo derecho del intervalo $[0, T]$ y el número de incrementos N de un camino browniano base. El propósito es calcular los incrementos de relleno de una refinamiento con $2N$ incrementos.

```python
import numpy as np
import matplotlib.pyplot as plt
prng = np.random.RandomState(10)

def refined_brownian_2n(T,L):
    dt = T / L
    W = np.zeros(L + 1)
    W_refined = np.zeros(2 * L + 1)
    xi = np.sqrt(dt) * prng.normal(size=L)
    xi_half = np.sqrt(0.5 * dt) * prng.normal(size=L)
    W[1:] = xi.cumsum()
    W_ = np.roll(W, -1)
    W_half = 0.5 * (W + W_)
    W_half = np.delete(W_half, -1) + xi_half
    W_refined[1::2] = W_half
    W_refined[2::2] = W[1:]
    t = np.arange(0, T + dt, dt)
    t_half = np.arange(0, T + 0.5 * dt, 0.5 * dt)
    return t, t_half, W, W_refined
```

En un script separado, incluya la función de arriba y grafique una figura con la trayectoria del browniano con 100 incrementos y muestre su refinamiento correspondiente.

```python
time, bi_time, w, bi_w = refined_brownian_2n(1,100)

plt.plot(time, w, 'b-+')
plt.plot(
    bi_time,
    bi_w,
    'ro--',
    alpha=0.5
)
plt.show()
```

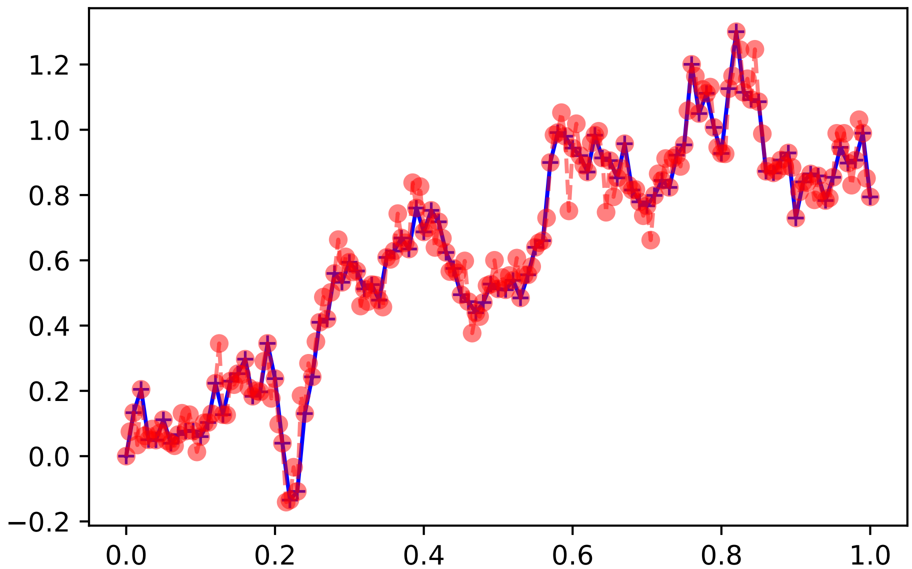
1.2
1.0
0.8
0.6
0.4
0.2
0.0
−0.2
0.0
0.2
0.4
0.6
0.8
1.0

14 Tarea 5

Exercise 14.1. Muestre que el movimiento Browniano satisface

$$E\left[|W(t)-W(s)|^2\right]=|t-s|$$

Si $t>s$.

$$\begin{aligned}E\left[|W(t)-W(s)|^2\right]&=E\left[(W(t)-W(s))^2\right]\\&=t-s,\end{aligned}$$

mientras que si $t\leq s$.

$$\begin{aligned}E\left[(W(t)-W(s))^2\right]&=E\left[(W(s)-W(t))^2\right]\\&=s-t,\end{aligned}$$

por lo tanto

$$E\left[|W(t)-W(s)|^2\right]=|t-s|$$

Exercise 14.2. Dado $W(t_i)$ y $W(t_{i+1})$, muestre que la variable aleatoria

$$W\left(t_{i+\frac{1}{2}}\right):=\frac{1}{2}\left[W(t_i)+W(t_{i+1})\right]+\frac{1}{2}\sqrt{\Delta t}\xi,\xi\sim N(0,1)$$

es un movimiento Browniano.

14.0.0.0.1 Es claro que al ser un refinamiento del movimiento browniano.

$$W(0)=0$$

14.0.0.0.2 C_2. Notemos que

$$W_{i+\frac{i}{2}} - W_i = \frac{1}{2}\left[W\left(t_{i+1}\right) - W\left(t_i\right)\right] + \frac{1}{2}\sqrt{\Delta t}\xi,$$

Sabemos que la combinación lineal de normales es una nornal. Luego, partiendo que $t_{i+1} - t_i = \Delta t$.

$$\begin{aligned} E\left[W_{i+\frac{i}{2}} - W_i\right] &= 0, \\ \operatorname{Var}\left[W_{i+\frac{i}{2}} - W_i\right] &= \frac{1}{4}\Delta t + \frac{1}{4}\Delta t = \frac{1}{2}\Delta t, \end{aligned}$$

Por lo tanto $W_{i+\frac{1}{2}} - W_i \sim N\left(0, \dfrac{\Delta t}{2}\right)$.

14.0.0.0.3 Calculamos la esperanza.

$$E\left[\left(W_{i+1} - W_{i+\frac{1}{2}}\right)\left(W_{j+1} - W_{j+\frac{1}{2}}\right)\right] = E\left[\left(\frac{1}{2}\left[W\left(t_{i+1}\right) - W\left(t_i\right)\right] + \sqrt{\frac{\Delta t}{4}}\xi\right)\frac{1}{2}\left[W\left(t_{j+1}\right) - W\left(t_j\right)\right] + \sqrt{\frac{\Delta t}{4}}\xi\right]$$

defina $dW_i = W_{i+1} - W_i$,

$$
\begin{aligned}
E\left[\left(W_{i+1}-W_{i+\frac{1}{2}}\right)\left(W_{j+1}-W_{j+\frac{1}{2}}\right)\right] &= E\left[\left(\frac{1}{2}dW_i+\sqrt{\frac{\Delta t}{4}}\xi\right)\left(\frac{1}{2}dW_j+\sqrt{\frac{\Delta t}{4}}\xi\right)\right]\\
&= E\left[\frac{1}{4}dW_idW_j+\frac{1}{2}dW_i\sqrt{\frac{\Delta t}{4}}\xi+\frac{1}{2}dW_j\sqrt{\frac{\Delta t}{4}}\xi+\left(\sqrt{\frac{\Delta t}{4}}\xi\right)^2\right]\\
dW_i, dW_j \text{ son independientes} &= \left(E\left[\frac{1}{2}dW_i\right]\right)\left(E\left[\frac{1}{2}dW_j\right]\right)+E\left[\frac{1}{2}dW_i\right]\sqrt{\frac{\Delta t}{4}}E\left[\xi\right]\\
&+E\left[\frac{1}{2}dW_j\right]\sqrt{\frac{\Delta t}{4}}E\left[\xi\right]+\frac{\Delta t}{4}\left(E\left[\xi\right]\right)^2\\
&= \left(E\left[\frac{1}{2}dW_i\right]\right)\left(E\left[\frac{1}{2}dW_j+\sqrt{\frac{\Delta t}{4}}\xi\right]\right)+E\left[\frac{1}{2}dW_j\right]\sqrt{\frac{\Delta t}{4}}E\left[\xi\right]+\frac{\Delta t}{4}(E\\
&= \left(E\left[\frac{1}{2}dW_i\right]\right)\left(E\left[\left(W_{j+1}-W_{j+\frac{1}{2}}\right)\right]\right)+E\left[\frac{1}{2}dW_j\right]\sqrt{\frac{\Delta t}{4}}E\left[\xi\right]+\frac{\Delta t}{4}(E\left[\xi\right]\\
&= \left(E\left[\frac{1}{2}dW_i\right]\right)\left(E\left[\left(W_{j+1}-W_{j+\frac{1}{2}}\right)\right]\right)+E\left[\frac{1}{2}dW_j+\sqrt{\frac{\Delta t}{4}}\xi\right]\sqrt{\frac{\Delta t}{4}}E\left[\xi\right]\\
&= \left(E\left[\frac{1}{2}dW_i\right]\right)\left(E\left[\left(W_{j+1}-W_{j+\frac{1}{2}}\right)\right]\right)+E\left[\left(W_{j+1}-W_{j+\frac{1}{2}}\right)\right]\sqrt{\frac{\Delta t}{4}}E\left[\xi\right]\\
&= E\left[\left(W_{i+1}-W_{i+\frac{1}{2}}\right)\right]E\left[\left(W_{j+1}-W_{j+\frac{1}{2}}\right)\right],
\end{aligned}
$$

teniendo asi, que los incrementos son independientes.

Exercise 14.3. Generalice la fórmula del ejercicio anterior para en el caso donde, $W\left(t_i\right), W\left(t_{i+1}\right)$, y $\alpha \in (0,1)$ el valor

$$W\left(t_i+\alpha\Delta t\right),$$

es un movimiento Browniano.

Notemos que

$$t_i+\alpha\Delta t+(1-\alpha)\Delta t = t_{i+1},$$

entonces vamos a definir

$$
\begin{aligned}
W_{i+\alpha} &= W\left(t_i+\alpha\Delta t\right)\\
&= (1-\alpha)W_i+\alpha W_{i+1}+Y,
\end{aligned}
$$

donde Y será una v.a independiente de $W(t)$. Entonces

$$
\begin{aligned}
W_{i+\alpha}-W_i &= (1-\alpha)W_i+\alpha W_{i+1}+Y-W_i\\
&= \alpha\left(W_{i+1}-W_i\right)+Y\\
&= \alpha\left(W_{i+1}-W_i\right)+Y.
\end{aligned}
$$

Entonces

$$E\left[W_{i+\alpha}-W_i\right]=E\left[Y\right],$$

por lo tanto, $E\left[Y\right]$ tiene que ser cero. Luego

$$\operatorname{Var}\left[W_{i+\alpha}-W_i\right]=\alpha^2\Delta t+\operatorname{Var}\left[Y\right],$$

notemos que

$$\left(i+\alpha\right)\Delta t-i\Delta t=\alpha\Delta t,$$

por lo tanto tendría que cumplirse $\operatorname{Var}\left[W_{i+\alpha}-W_i\right]=\alpha\Delta t$.

$$\alpha^2\Delta t+\operatorname{Var}\left[Y\right]=\alpha\Delta t,$$

entonces

$$\operatorname{Var}\left[Y\right]=\Delta t\left(\alpha-\alpha^2\right),$$

como $Y=\sqrt{\alpha\left(1-\alpha\right)}\xi,\xi\sim N\left(0,1\right)$. Como este es un refinamiento del browniano, entonces se cumple $C1$.

$$W\left(0\right)=0.$$

Conseguimos $C2$ por construcción y de forma análoga tenemos la independiencia de los incrementos.

$$E\left[\left(W_{i+\alpha}-W_i\right)\left(W_{j+\alpha}-W_j\right)\right]=E\left[W_{i+\alpha}-W_i\right]E\left[W_{j+\alpha}-W_j\right].$$

Exercise 14.4. Suponga que $X\sim N\left(0,1\right)$. Sabemos que $E\left[X\right]=0$ y $E\left[X^2\right]=3$. Luego, de la definición, el $p-$ ésimo momento satisface

$$E\left[X^p\right]=\frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty}x^p\exp\left(-\frac{x^2}{2}\right)\mathrm{D}x.$$

Usando la relación, muestre que $E\left[X^3\right]=0$ y $E\left[X^4\right]=1$.

Entonces deduzca el incremento Browniano,

$$\Delta W_i=W\left(t_{i+1}\right)-W\left(t_i\right),$$

satisface $E\left[\Delta W_i^3\right]=0,E\left[\Delta W_i^4\right]=3\left(\Delta t\right)^2$. Entonces encuentre una expresión para $E\left[X^p\right]$ para un entero positivo $p.\backslash$ Pista: Tu puedes usar el dato que $\int_{-\infty}^{\infty}\exp\left(-\frac{x^2}{2}\right)=\sqrt{2\pi}$.

Considere la fórmula.

$$E\left[X^p\right] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x^p \exp\left(-\frac{x^2}{2}\right) \mathrm{D}x.$$

Partiendo la integral,

$$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x^p \exp\left(-\frac{x^2}{2}\right) \mathrm{D}x = \underbrace{\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{0} x^p \exp\left(-\frac{x^2}{2}\right) \mathrm{D}x}_{I_1} + \underbrace{\frac{1}{\sqrt{2\pi}} \int_{0}^{\infty} x^p \exp\left(-\frac{x^2}{2}\right) \mathrm{D}x}_{I_2}$$

Entonces

$$I_1 = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{0} x^p \exp\left(-\frac{x^2}{2}\right) \mathrm{D}x,$$

hagamos el cambio de variable. $y = -x$, tenemos que

$$\begin{aligned} I_1 &= \frac{1}{\sqrt{2\pi}} \int_{\infty}^{0} -(-y)^p \exp\left(-\frac{y^2}{2}\right) \mathrm{D}y \\ &= \frac{(-1)^p}{\sqrt{2\pi}} \int_{0}^{\infty} y^p \exp\left(-\frac{y^2}{2}\right) \mathrm{D}y = I_2 (-1)^p, \end{aligned}$$

entonces

$$E\left[X^p\right] = \left(1 + (-1)^p\right) I_2,$$

de aqui tenemos, que si p es impar $E\left[X^p\right] = 0$, entonces si p es par

$$E\left[X^p\right] = 2I_2,$$

entonces, nos concentraremos en

$$E\left[X^p\right] = \frac{2}{\sqrt{2\pi}} \int_{0}^{\infty} x^p \exp\left(-\frac{x^2}{2}\right) \mathrm{D}x, p = 2k, k \in \mathbb{N}$$

Considere $y = \dfrac{x^2}{2}, \mathrm{D}y = x\mathrm{D}x$.

$$E\left[X^p\right] = \frac{2}{\sqrt{2\pi}} \int_{0}^{\infty} x^{p-1} \exp\left(-y\right) \mathrm{D}y,$$

luego $\sqrt{2y} = x$, entonces

$$\begin{aligned}
E\left[X^p\right] &= \frac{2}{\sqrt{2\pi}} \int_0^\infty \left(\sqrt{2y}\right)^{p-1} \exp\left(-y\right) \mathrm{D}y \\
&= \frac{2\left(\sqrt{2}\right)^{p-1}}{\sqrt{2\pi}} \int_0^\infty y^{\frac{p-1}{2}} \exp\left(-y\right) \mathrm{D}y \\
&= \frac{2\left(\sqrt{2}\right)^{p-1}}{\sqrt{2\pi}} \int_0^\infty y^{\frac{p+1}{2}-1} \exp\left(-y\right) \mathrm{D}y,
\end{aligned}$$

recordando la función Gamma.

$$\Gamma\left(z\right) = \int_0^\infty x^{z-1} e^{-t} \mathrm{D}t,$$

entonces

$$E\left[X^p\right] = \begin{cases} 0 & p \text{ impar} \\ \dfrac{2^{\frac{p+1}{2}}}{\sqrt{2\pi}} \Gamma\left(\dfrac{p+1}{2}\right) & p \text{ par} \end{cases},$$

entonces $E\left[X^4\right] = \dfrac{4}{\sqrt{\pi}} \Gamma\left(\dfrac{5}{2}\right)$

$$\Gamma\left(\frac{5}{2}\right) = \int_0^\infty x^{\frac{3}{2}} e^{-x} \mathrm{D}x.$$

Considere

$$\begin{aligned}
u = x^{3/2} \mathrm{D}v = e^{-x} \mathrm{D}x \\
\mathrm{D}u = \frac{3}{2} x^{1/2} v = -e^{-x},
\end{aligned}$$

$$\begin{aligned}
\Gamma\left(\frac{5}{2}\right) &= \left[-x^{3/2} e^{-x}\right] + \frac{3}{2} \int_0^\infty x^{1/2} e^{-x} \mathrm{D}x \\
&= \frac{3}{2} \frac{\sqrt{\pi}}{2}.
\end{aligned}$$

Entonces

$$E\left[X^4\right] = 3$$

Notemos que si $\Delta W \sim N\left(0, \sigma^2\right)$, entonces

$$Z = \frac{\Delta W}{\sigma} \sim N\left(0,1\right)$$

En general,

$$E\left[\left(\Delta W\right)^p\right] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} w^p \exp\left(-\left(\frac{w}{\sigma}\right)^2\right) \mathrm{D}w,$$

considere $\sigma u = w$, entonces

$$\begin{aligned} E\left[\left(\Delta W\right)^p\right] &= \sigma^p \left[\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} u^p \exp\left(-u^2\right) \mathrm{D}w\right], \\ &= \sigma^p E\left[Z^p\right], \end{aligned}$$

entonces para $p = 4, \sigma^2 = \Delta t$.

$$E\left[\left(\Delta W\right)^4\right] = \left(\Delta t\right)^2 E\left[Z^4\right] = 3\left(\Delta t\right)^2$$

Exercise 14.5. Suponga que $X \sim N\left(0,1\right)$. Muestre que para $a, b \in \mathbb{R}$,

$$E\left[\exp\left(a + bX\right)\right] = \exp\left(a + \frac{1}{2}b^2\right).$$

Deduzca que

$$E\left[\exp\left(t + \frac{1}{4}W_t\right)\right] = \exp\left(\frac{33}{32}t\right)$$

Considere

$$E\left[\exp\left(a + bX\right)\right] = e^a E\left[\exp\left(bX\right)\right],$$

notemos que $bX \sim N\left(0, b^2\right)$, por lo tanto, la función generadora de momentos nos dice que

$$E\left[\exp\left(bX\right)\right] = M_{bX}\left(1\right) = \exp\left(\frac{b^2}{2}\right),$$

por lo tanto

$$E\left[\exp\left(a + bX\right)\right] = e^a \exp\left(\frac{b^2}{2}\right) = \exp\left(a + \frac{1}{2}b^2\right),$$

ahora, considere

$$E\left[\exp\left(t + \frac{1}{4}W_t\right)\right] = E\left[\exp\left(t + \frac{1}{4}\left(W_t - W_0\right)\right)\right],$$

Notemos que $W_t - W_0 \sim N\left(0, t\right)$, por lo tanto, usando la fórmula anterior

$$
\begin{aligned}
E\left[\exp\left(t+\frac{1}{4}\left(W_t-W_0\right)\right)\right] &= \exp\left(t+\frac{1}{4}\left(\sqrt{t}X\right)\right), X\sim N\left(0,1\right)\\
&= \exp\left(t+\left(\frac{1}{4}\sqrt{t}\right)X\right) = \exp\left(t+\frac{t}{32}\right)\\
&= \exp\left(\frac{33}{32}t\right)
\end{aligned}
$$

15 Tarea 6

Exercise 15.1. Hacer un script para simular 10000 trayectorias del proceso $u(t, W_t)$ definido en el Ejercicio. Grafique en una figura, 10 trayectorias y la media de las 10000 trayectorias del proceso $u(t, W_t)$.

```
import numpy as np
import matplotlib.pyplot as plt

def strong_brownian(t, n):
    dt = t / n
    dw = np.zeros(n)
    w = np.zeros(n)
    for i in np.arange(1, n):
        dw[i] = np.sqrt(dt)*np.random.standard_normal()
        w[i] = w[i - 1] + dw[i]
    time = np.linspace(0, t, n)
    return time, w



def b_function(t, a, w):
    y = np.exp(t - a * w)
    return y


n_samples = 10000
n_points = 64
t_initial = 0
t_final = 1

mean = np.zeros(n_points)
for i in range(n_samples):
    time, b_w = strong_brownian(t_final, n_points)
    y = b_function(time, 0.25, b_w)
    if i < 10:
```

```
        plt.plot(time, b_w, 'g-', alpha=0.5)
    mean += y

mean = (n_samples)**(-1) * mean
time = np.linspace(0, t_final, n_points)

y = [np.exp(33 / 32 * t) for t in time]
plt.plot(time, mean, 'r-')
plt.plot(time, y, 'b-', alpha=0.3)
plt.show()
```

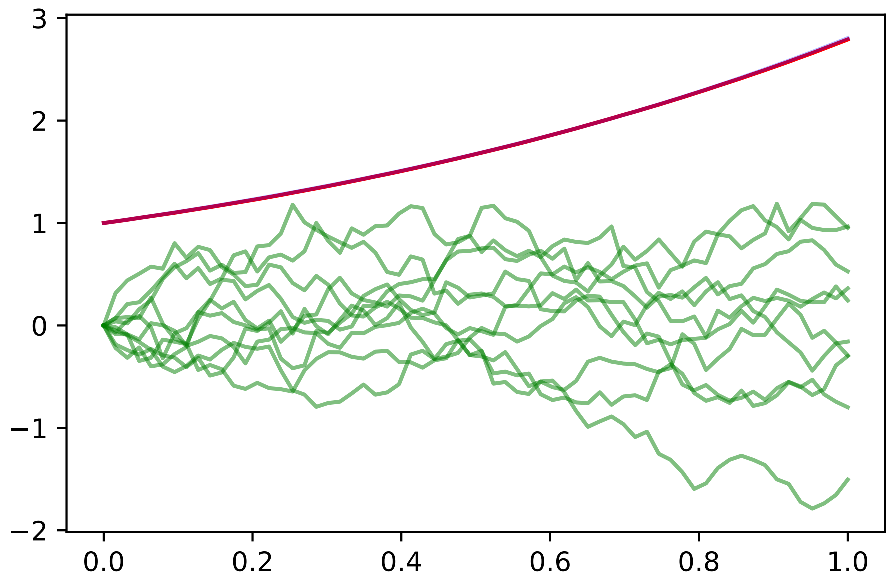

Exercise 15.2. Siguiendo las ideas del refinamiento del camino browniano. $t_{i+1/2} = t_i + \frac{1}{2}\delta t$. Hacer un código de Python para el refinamiento del Browniano para $\alpha \in (0,1)$ para el refinamiento $t_{i+ } = t_i + t $

```
import numpy as np
import matplotlib.pyplot as plt

def strong_brownian(t, n):
    dt = t / n
    dw = np.zeros(n)
    w = np.zeros(n)
```

```
    for i in np.arange(1, n):
        dw[i] = np.sqrt(dt)*np.random.standard_normal()
        w[i] = w[i - 1] + dw[i]
    time = np.linspace(0, t, n)
    return time, w

t_final = 1
n_points = 65
delta_t = 1/(n_points - 1)
alpha = 0.7

prng = np.random.RandomState(219)

time, w = strong_brownian(1, n_points)  # w_i

y = np.sqrt(delta_t * (alpha - alpha ** 2)) * prng.standard_normal(n_points - 1)

w_ = np.roll(w, -1)  # w_i+1

w_alpha = alpha * w_ + (1 - alpha) * w
w_alpha = np.delete(w_alpha, -1)
w_alpha += y
w_ref = np.zeros(2* n_points -1)

w_ref[0::2] = w
w_ref[1::2] = w_alpha

time_ref = np.zeros(2 * n_points - 1)

for i in range(2 * n_points - 1):
    if i % 2 == 0:
        time_ref[i] = time[int(i / 2)]
    else:
        time_ref[i] = time[int(i / 2)] + alpha * delta_t

plt.plot(time_ref, w_ref, 'g-')
plt.plot(time, w, 'ro')
plt.show()
```

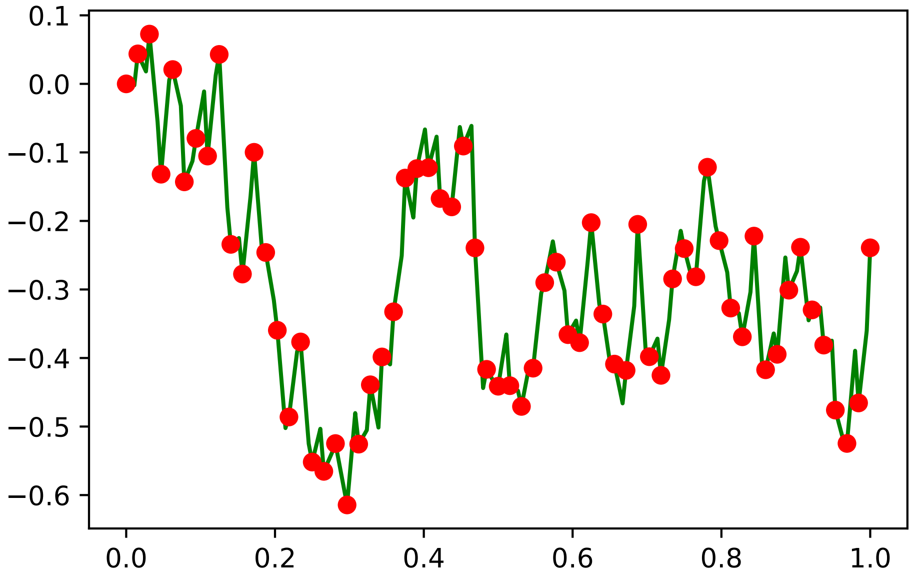
0.1
0.0
−0.1
−0.2
−0.3
−0.4
−0.5
−0.6
0.0
0.2
0.4
0.6
0.8
1.0

16 Tarea 7

Sea τ un tiempo de paro. Prueba que $W(t+\tau) - W(\tau)$ es un movimiento browniano.

Sea τ un tiempo de paro. Prueba que $W(t+\tau) - W(\tau)$ es un movimiento browniano.

Sea τ un tiempo de paro. Prueba que $W(t+\tau) - W(\tau)$ es un movimiento browniano.

Sea τ un tiempo de paro. Prueba que $W(t+\tau) - W(\tau)$ es un movimiento browniano.

Sea τ un tiempo de paro. Prueba que $W(t+\tau) - W(\tau)$ es un movimiento browniano.

Sea τ un tiempo de paro. Prueba que $W(t+\tau) - W(\tau)$ es un movimiento browniano.

17 Tarea 8

Use la aproximación de la suma de Riemann la ecuación 6.1. Muestra la propiedad de linealidad de la integral estocástica. Es decir,

$$\int_0^T (\alpha f(t) + \beta g(t))\, dW_t = \alpha \int_0^T f(t) dW_t + \beta \int_0^T g(t) dW_t$$

Sea $\{0 = t_0, t_1, \dots, t_{L-1}, t_L = T\}$ una particion del intervalo $[0, T]$, de la aproximación de la suma de Riemann, resulta

$$\begin{aligned}
\int_0^T (\alpha f(t) + \beta g(t))\, dW_t \quad &\sim \quad \sum_{i=0}^{L} (\alpha f(t_i) + \beta g(t_i))(W(t_{i+1}) - W(t_i)) \\
&= \quad \sum_{i=0}^{L} \alpha f(t_i)(W(t_{i+1}) - W(t_i)) + \sum_{i=0}^{L} \beta g(t_i)(W(t_{i+1}) - W(t_i)) \\
&= \quad \alpha \sum_{i=0}^{L} f(t_i)(W(t_{i+1}) - W(t_i)) + \beta \sum_{i=0}^{L} g(t_i)(W(t_{i+1}) - W(t_i))
\end{aligned}$$

tomando el limite cuando $L \to \infty$, resulta

$$\alpha \lim_{L\to\infty} \sum_{i=0}^{L} f(t_i)(W(t_{i+1}) - W(t_i)) = \alpha \int_0^T f(t) dW_t$$

y

$$\beta \lim_{L\to\infty} \sum_{i=0}^{L} g(t_i)(W(t_{i+1}) - W(t_i)) = \beta \int_0^T g(t) dW_t$$

así,

$$\int_0^T (\alpha f(t) + \beta g(t))\, dW_t = \alpha \int_0^T f(t) dW_t + \beta \int_0^T g(t) dW_t$$

Escriba con detalle la demostración del siguiente Teorema, también incluya la demostración del Lema 5.18 del Mao.\ Teorema: Sea $f \in \mathcal{M}^2([0, T]; \mathbb{R})$, sea ρ, τ dos tiempos de paro tales que $0 \leq \rho \leq \tau \leq T$. Entonces

$$\begin{aligned} \mathbb{E}\left(\int_{\rho}^{\tau} f(s)dW_s \mid \mathcal{F}_{\rho}\right) &= 0, && (17.1)\\ \mathbb{E}\left(\left|\int_{\rho}^{\tau} f(s)dW_s\right|^2 \mid \mathcal{F}_{\rho}\right) &= \mathbb{E}\left(\int_{\rho}^{\tau} |f(s)|^2\, ds \mid \mathcal{F}_{\rho}\right). && (17.2)\end{aligned}$$

Por el Teorema 5.14 y el teorema de paro de la martingala de Doob,

$$E(I(\tau)|\mathcal{F}_{\rho}) = I(\rho) \tag{17.3}$$

y

$$E(I^2(\tau) - \langle I, I\rangle_{\tau}|\mathcal{F}_{\rho}) = I^2(\rho) - \langle I, I\rangle_{\rho}, \tag{17.4}$$

donde $\{\langle I, I\rangle_t\}$ es definido por 5.18. Aplicando el Lema 5.18 se ve entonces de 5.22 que

$$\mathbb{E}\left(\int_{\rho}^{\tau} f(s)dB_s|\mathcal{F}_{\rho}\right) = \mathbb{E}(I(\tau) - I(\rho)|\mathcal{F}_{\rho}) = 0$$

que es (5.20). Además, por (5.22) y (5.23),

$$\mathbb{E}(|I(\tau) - I(\rho)|^2|\mathcal{F}_{\rho}) = \mathbb{E}(I^2(\tau)|\mathcal{F}_{\rho}) - 2I(\rho)\mathbb{E}(I(\tau)|\mathcal{F}_{\rho}) + I^2(\rho)$$

$$= \mathbb{E}(I^2(\tau)|\mathcal{F}_{\rho}) - I^2(\rho) = \mathbb{E}(\langle I, I\rangle_{\tau} - \langle I, I\rangle_{\rho}|\mathcal{F}_{\rho}) = \mathbb{E}\left(\int_{\rho}^{\tau} |f(s)|^2 ds|\mathcal{F}_{\rho}\right)$$

Usando la aproximación de la suma de Riemann ecuación 6.1, la isometría de Itô y la identidad $4ab = (a+b)^2 - (a-b)^2$ pruebe que

$$\mathbb{E}\left[\left(\int_0^T g(t)dW_t\right)\left(\int_0^T f(t)dW_t\right)\right] = \int_0^T \mathbb{E}[f(t)g(t)]dt.$$

Tomemos $a = \int_0^T g(t)dW_t$ y $b = \int_0^T f(t)dW_t$, entonces usando la identidad $4ab = (a+b)^2 - (a-b)^2$

$$\begin{aligned} 4\left(\int_0^T g(t)dW_t\right)\left(\int_0^T f(t)dW_t\right) &= \left(\int_0^T g(t)dW_t + \int_0^T f(t)dW_t\right)^2 - \left(\int_0^T g(t)dW_t - \int_0^T f(t)dW_t\right)^2\\ &= \left(\int_0^T (g(t)+f(t))dW_t\right)^2 - \left(\int_0^T (g(t)-f(t))dW_t\right)^2, \end{aligned}$$

así,

$$
\begin{aligned}
4\mathbb{E}\left[\left(\int_0^T g(t)dW_t\right)\left(\int_0^T f(t)dW_t\right)\right] &= \mathbb{E}\left(\int_0^T (g(t)+f(t))dW_t\right)^2 - \mathbb{E}\left(\int_0^T (g(t)-f(t))dW_t\right)^2 \\
&= \left(\int_0^T \mathbb{E}(g(t)+f(t))^2 dt\right) - \left(\int_0^T \mathbb{E}(g(t)-f(t))^2 dt\right) \\
&= \left(\int_0^T \mathbb{E}[(g(t)+f(t))^2-(g(t)-f(t))^2]dt\right) \\
&= 4\left(\int_0^T \mathbb{E}[g(t)f(t)]dt\right)
\end{aligned}
$$

Usando la suma de Riemann ecuación 6.1 y deduzca que,

$$
\int_0^T W(t)^2 dW(t) = \frac{1}{3}W(T)^3 - \int_0^T W(t)dt.
$$

Observemos que,

$$
3W(t_i)^2(W(t_{i+1})-W((t_i))) = W(t_{i+1})^3-\left(W(t_{i+1})-W(t_i)\right)^3-3\left(W(t_{i+1})-W(t_i)\right)^2 W(t_i)-W(t_{i-1})^3,
$$

aplicando la ecuación 6.1

$$
\begin{aligned}
\int_0^T W(t)^2 dW(t) \sim \sum_{i=0}^{L} W(t_i)^2(W(t_{i+1})-W((t_i))) \\
&= \frac{1}{3}\sum_{i=0}^{L}[W(t_{i+1})^3-W(t_{i-1})^3] - \frac{1}{3}\sum_{i=0}^{L}\left(W(t_{i+1})-W(t_i)\right)^3 - \sum_{i=0}^{L}\left(W(t_{i+1})-W(t_i)\right)^2 W(t_i) \\
&= \frac{1}{3}(W(T)^3-W(t_0)^3) - \frac{1}{3}\sum_{i=0}^{L}\left(W(t_{i+1})-W(t_i)\right)^3 - \sum_{i=0}^{L}\left(W(t_{i+1})-W(t_i)\right)^2 W(t_i) \\
&= \frac{1}{3}W(T)^3 - \frac{1}{3}\sum_{i=0}^{L}\left(W(t_{i+1})-W(t_i)\right)^3 - \sum_{i=0}^{L}\left(W(t_{i+1})-W(t_i)\right)^2 W(t_i)
\end{aligned}
$$

veamos que $\frac{1}{3}\sum_{i=0}^{L}\left(W(t_{i+1})-W(t_i)\right)^3 \to 0$ en L^2.\ Ahora, calcularemos la media de la variación cuadrática. Del Teorema Multinomial

$$
\frac{1}{9}\mathbb{E}\left[\left(\sum_{i=0}^{L}\left(W(t_{i+1})-W(t_i)\right)^3\right)^2\right] = \frac{1}{9}\sum_{i=0}^{L}\mathbb{E}\left[\left(W(t_{i+1})-W(t_i)\right)^6\right]+\frac{2}{9}\sum_{i=0}^{L}\mathbb{E}\left[\left(W(t_{i+1})-W(t_i)\right)^3\left(W(t_{j+1})-W
$$

además, de la tarea 5,

$$\begin{aligned}
\mathbb{E}\left[\left(W(t_{i+1})-W(t_i)\right)^3\left(W(t_{j+1})-W(t_j)\right)^3\right] &= \mathbb{E}\{\mathbb{E}\left[\left(W(t_{i+1})-W(t_i)\right)^3\left(W(t_{j+1})-W(t_j)\right)^3\right]|\mathcal{F}_j\} \\
&= \mathbb{E}\{\left(W(t_{i+1})-W(t_i)\right)^3\mathbb{E}\left[\left(W(t_{j+1})-W(t_j)\right)^3\Big|\mathcal{F}_j\right]\} \\
&= \mathbb{E}[\left(W(t_{i+1})-W(t_i)\right)^3]\mathbb{E}\left[\left(W(t_{j+1})-W(t_j)\right)^3\right] \\
&= 0. \text{ de la tarea 5}
\end{aligned}$$

así,

$$\frac{2}{9}\sum_{i=0}^{L}\mathbb{E}\left[\left(W(t_{i+1})-W(t_i)\right)^3\left(W(t_{j+1})-W(t_j)\right)^3\right]=0$$

y también se tiene que $\mathbb{E}\left[\left(W(t_{i+1})-W(t_i)\right)^6\right]=15\left(t_{i+1}-t_i\right)^3$, así

$$\begin{aligned}
\frac{1}{9}\sum_{i=0}^{L}E\left[\left(W(t_{i+1})-W(t_i)\right)^6\right] &= \frac{5}{3}\sum_{i=0}^{L}\left(t_{i+1}-t_i\right)^3 \\
&\leq \frac{5}{3}\|\Delta_L\|^2\sum_{i=0}^{L}\left(t_{i+1}-t_i\right) \\
&\leq \frac{5}{3}\|\Delta_L\|^2 L\to 0, \|\Delta_L\|\to 0
\end{aligned}$$

Ahora veamos que

$$\sum_{i=0}^{L}\left(W(t_{i+1})-W(t_i)\right)^2 W(t_i)\to\sum_{i=0}^{L}W(t_i)\left(t_{i+1}-t_i\right)\ \text{ en } L^2$$

se tiene que,

$$\mathbb{E}\left[\left(\sum_{i=0}^{L}\left(W(t_{i+1})-W(t_i)\right)^2 W(t_i)-\sum_{i=0}^{L}W(t_i)\left(t_{i+1}-t_i\right)\right)^2\right] = \mathbb{E}\left[\left(\sum_{i=0}^{L}W(t_i)[\left(W(t_{i+1})-W(t_i)\right)^2-(t_{i+1}\right.\right.$$

$$\mathbb{E}\left[\sum_{i=0}^{L}W(t_i)^2[\left(W(t_{i+1})-W(t_i)\right)^2-(t_{i+1}-t_i)]^2+\sum_{i=0}^{L}W(t_i)W(t_j)[\left(W(t_{i+1})-W(t_i)\right)^2-(t_{i+1}-t_i)][(W(t_{j+1})\right.$$

calculemos

$$\mathbb{E}\{\mathbb{E}[W(t_i)W(t_j)((W(t_{i+1})-W(t_i))^2-(t_{i+1}-t_i))((W(t_{j+1})-W(t_j))^2-(t_{j+1}-t_j))]|\mathcal{F}_j\} =$$

$$\mathbb{E}\{W(t_i)W(t_j)((W(t_{i+1})-W(t_i))^2-(t_{i+1}-t_i))\mathbb{E}[((W(t_{j+1})-W(t_j))^2-(t_{j+1}-t_j))]|\mathcal{F}_j\}=0$$

Verifique que la isometría de Itô ecuación 6.4,

$$\mathbb{E}\left[\left(\int_0^T h(t)dW(t)\right)^2\right] = \mathbb{E}\left[\int_0^T h(t)^2 dt\right],$$

se tiene cuando $h(t) := 1$.

del ejercicio 3, resulta

$$\begin{aligned}
\mathbb{E}\left[\left(\int_0^T h(t)dW(t)\right)^2\right] = \mathbb{E}\left[\left(\int_0^T 1dW(t)\right)^2\right] &= \mathbb{E}\left[\left(\int_0^T 1dW_t\right)\left(\int_0^T 1dW_t\right)\right] \\
&= \int_0^T \mathbb{E}[1]dt \\
&= \int_0^T dt \\
&= T.
\end{aligned}$$

y

$$\begin{aligned}
\mathbb{E}\left[\int_0^T h(t)^2 dt\right] &= \mathbb{E}\left[\int_0^T 1^2 dt\right] \\
&= \mathbb{E}\left[\int_0^T dt\right] \\
&= \mathbb{E}\left[T\right] \\
&= T
\end{aligned}$$

Así,

$$\mathbb{E}\left[\left(\int_0^T dW(t)\right)^2\right] = \mathbb{E}\left[\int_0^T dt\right]$$

18 Tarea 9

Sea τ un tiempo de paro. Prueba que $W(t+\tau)-W(\tau)$ es un movimiento browniano.

Definamos

$$V_\tau(t)=W(t+\tau)-W(\tau),$$

notemos que

$$V_\tau(0)=0,$$

Luego, considere para $s\leq t$

$$\begin{aligned}V_\tau(t)-V_\tau(s)&=W(t+\tau)-W(\tau)-[W(s+\tau)-W(\tau)]\\&=W(t+\tau)-W(s+\tau)\sim N(0,t-s),\end{aligned}$$

esto además nos garantiza la independencia de los incrementos del Browniano.

Sea $W_1(t),W_2(t)$ movimientos brownianos independientes con punto inicial $(W_1(0),W_2(0))\neq(0,0)$. Defina $X_t=\ln\left(W_1^2(t)+W_2^2(t)\right)$.

18.0.1 Muestre que X_t es una martingala local.

Supongamos que X_t NO es una martingala local.

18.0.2 Muestre que $E|X_t|<\infty$ para cada $t>0$.

Considere

$$\begin{aligned}X_t&=\ln\left(W_1^2(t)+W_2^2(t)\right),\\\exp(X_t)&=W_1^2(t)+W_2^2(t).\end{aligned}$$

$$\begin{aligned}E[\exp(X_t)]&=E\left[W_1^2(t)\right]+E\left[W_2^2(t)\right]\\&=2t,\end{aligned}$$

Como $X_t \geq 0, \forall t$

$$X_t \leq \exp(X_t)$$
$$E[X_t] \leq 2t < \infty, \forall t$$

18.0.3 Muestre que X_t no es una martingala.

Supongamos que existe $c \in \mathbb{R}$ tal que $E[X_t] = c, \forall t$. Entonces

$$E\left[\ln\left(W_1^2(t) + W_2^2(t)\right)\right] = c$$
$$\int_0^\infty \ln\left(W_1^2(t) + W_2^2(t)\right) \mathrm{d}\mathcal{P} = c,$$

Como la integral es finita. Entonces

$$X_t \to 0, t \to \infty, \text{ c.s}$$

Luego,

$$W_1^2(t) + W_2^2(t) \to 1, t \to \infty, \text{c.s}$$

Sin embargo

$$E\left[W_1^2(t) + W_2^2(t)\right] = 2t \to \infty, t \to \infty,$$

entonces llegamos a una contradicci'on. Entonces $E[X_t]$ no es constante, por lo tanto X_t no puede ser martingala.

Considere

$$\tau_n = \inf_t \{X_t = n\}$$

Como X_t es no acotada. Entonces

$$\tau_n(\omega) \to \infty, n \to \infty, \forall n.$$

Ahora probaremos que Y_t es una martingala. Ahora, considere

$$Y_t = X_{\min\{t, \tau_n\}},$$

es adaptado con respecto a la filtración. Si $\tau_n > t$ lo tenemos por construcción. En caso contrario, para $n \in \mathbb{N}$.

$$Y_t = n$$

$$[Y_t = n] \subset [\tau_n < t] \in \mathcal{F}_t,$$

por ser tiempo de paro. Por lo tanto Y_t es adaptado a la filtración, por lo tanto nos queda probar que es una martingala.

Considere $s < t$.

$$\begin{aligned}
E\left[Y_t \mid \mathcal{F}_s\right] &= E\left[X_{\min\{t,\tau_n\}} \mid \mathcal{F}_s\right] \\
&= E\left[X_t 1_{[t<\tau_n]}(t) \mid \mathcal{F}_s\right] + E\left[X_t 1_{[\tau_n \leq t]}(t) \mid \mathcal{F}_s\right] \\
&= E\left[X_s 1_{[s<\tau_n]}(t) \mid \mathcal{F}_s\right] + E\left[X_{\tau_n} 1_{[\tau_n \leq t]}(t) \mid \mathcal{F}_s\right] \\
&= X_s 1_{[s<\tau_n]}(t) + X_{\tau_n} 1_{[\tau_n \leq s]}(s) \\
&= Y_s,
\end{aligned}$$

teniendo así que para cada n Y_t es una martingala.

19 Tarea 10

References